


Дървовидни Алгоритми в AI

Пълен академичен анализ: От класически дървета на решения до върхови ансамблови модели

История и Еволюция



Разделяй и Владей

Основната парадигма на дърветата е "Разделяй и владей" (Divide and Conquer). Алгоритъмът систематично разчленява пространството от признаци на хипер-правоъгълници, във всеки от които предсказанието е константа. Този геометричен подход позволява на модела да улавя сложни, нелинейни зависимости, които са напълно недостъпни за класическите линейни модели.



Класически Алгоритми



ID3

Създаден от Рос Куинлан.

Използва **Информационната печалба** като основен критерий. Работи само с номинални (категорийни) признаци и предпочита такива с много категории.



C4.5

Еволюцията на ID3. Въвежда работа с числови стойности чрез прагови разделяния и механизъм за подрязване (Pruning). Използва **Gain Ratio** за нормализация.



CART

Модерният стандарт.

Генерира стриктно бинарни дървета (два клона на възел). Поддържа както класификация (чрез Gini), така и регресия (чрез MSE).

Критерии за Класификация

Нечистота на Джини (Gini)

Измерва вероятността случаен елемент да бъде грешно класифициран. Стойност 0 означава перфектна хомогенност. Ефективна за масиви от големи данни.

$$\text{Gini} (D) = 1 - \sum_{i=1}^c (p_i)^2$$

Ентропия (Entropy)

Концепция от теорията на информацията на Клод Шанън, която измерва хаоса. Информационната печалба е намалението на ентропията след разделяне.

$$\text{Entropy} = - \sum_{i=1}^c p_i \log_2 (p_i)$$

Критерии за Регресия

Mean Squared Error (MSE)

При непрекъснати променливи, алгоритъмът минимизира сумата от квадратите на разликите между реалните стойности и предсказаната средна стойност в листото.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

Mean Absolute Error (MAE)

Много по-устойчива метрика при наличие на екстремни отклонения (outliers) в данните. Тя минимизира сумата от абсолютните разлики.


$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}|$$

Проблемът с Преобучаването

Дърветата на решенията са склонни да растат безкрайно, докато не обхванат всеки детайл и шум в данните. Това води до преобучаване (overfitting).

Справяме се с този проблем чрез регуларизация:

- ▶ **Пре-подрязване (Pre-pruning):** Задаване на стриктни лимити по време на обучението, като максимална дълбочина (Max Depth) или минимален брой примери в листо.
- ▶ **Пост-подрязване (Post-pruning):** Позволява се на дървото да израсне напълно, след което систематично се премахват клони, които не допринасят за генерализацията (напр. Cost Complexity Pruning).



Ансамблово Обучение

Bagging и Random Forest

Комбинираща много "слаби" дървета за създаване на силен модел чрез **паралелизъм**. Всяко дърво се обучава върху случайна извадка от данните и използва случайно подмножество от признаците. Когато едно дърво сгреша, останалите компенсират чрез мажоритарно гласуване.

Boosting и XGBoost

Работи чрез строга **последователност**. Всяко ново дърво се фокусира изключително върху примерите, които предходните са сгрешили. Градиентният бустинг използва математическа оптимизация (Gradient Descent) върху загубната функция за постигане на максимална прецизност.

Индустриални Приложения



Netflix & Amazon

Препоръчителни системи

XGBoost / CatBoost

Класиране на продукти и филми чрез обработка на милиони категории признаци.



PayPal & Banks

Откриване на измами

Random Forest

Засичане на подозрителни шаблони (fraud detection) в реално време с висока точност.



NASA

Анализ на данни

Decision Trees

Класификация на небесни тела; интерпретируемостта помага за разбиране на физическите закони.



Uber

Предсказване на ETA

Tree Ensembles

Предвиждане на трафика и времето за пристигане чрез комбиниране на пространствени данни.

Любопитни факти и ключови разлики



Тухлата срещу Къщата

CART е "тухлата" (основният елемент), а **XGBoost/Random Forest** са "къщата" (цялостната конструкция). Не можеш да имаш ансамбъл без базовото дърво.



Бинарно срещу Многократно

CART винаги се разделя на две (Да/Не). ID3 и C4.5 могат да се разделят на много клони едновременно, което ги прави по-трудни за изчисляване при големи данни.



Защо Gini спечели?

В CART стандартът е **Gini**, защото не изисква логаритмични изчисления. Това прави CART много по-бърз за компютрите, когато трябва да построят хиляди дървета.



Overfitting = "Зубрене"

Преобучаването е когато дървото "назубри" конкретните данни, вместо да разбере логиката. Подрязването (Pruning) го кара да "забрави" излишните детайли.


Ключово Предимство



Дърветата на решенията остават един от най-важните инструменти в арсенала на всеки специалист по данни, предлагайки уникален баланс между прозрачност, скорост и изчислителна мощ.



— ЗАКЛЮЧЕНИЕ НА АКАДЕМИЧНИЯ АНАЛИЗ

The background is a vibrant blue digital scene. On the left, a white and blue humanoid robot is shown in profile, facing right. In the center, a glowing blue square contains the letters 'AI' in white. To the right, the upper half of a man in a dark blue suit and tie is visible. The background is filled with glowing blue circuit lines, hexagonal icons (including gears, a brain, a padlock with a dollar sign, a bar chart, and a waveform), and a faint grid pattern.

Бъдещето на AI

В свят на сложни "черни кутии", интерпретируемостта и ясните логически пътища на дървовидните модели ги правят незаменими за Системите с Обясним Изкуствен Интелект (XAI).

Въпроси и Дискусия?

Благодаря за вниманието.