



Тема 3: Машинно обучение

Типове задачи. Един, два или много класове. Разпознаване, локализация, проследяване. Примери

Съдържание

- ❑ Таксономия на методите
- ❑ Кой класификатор е най-добър?
- ❑ Дефиниции на решаваните задачи от перспектива на крайния потребител. Архитектури.
- ❑ Процес на обучение и работа на класификаторите
- ❑ Ресурси използвани при създаването на ML модели



Таксономия на методите

□ Обучение на моделите

- С надзор (supervised learning)
- Без надзор (unsupervised learning)
- С частичен надзор (Semi-supervised learning)
- С поощрение/подсилване/ (Reinforcement Learning)
- Активно обучение (Active learning)

□ Според принципа на учене

- Архитектури обучавани единствено чрез наблюдение
- Методи позволяващи интегриране на знание

□ Епизодични или последователни

- Вземат решение единствено въз основа на текущия вход
- Вземат решение въз основа на текущи и предходни входни или изходни състояния или вътрешни състояния

Таксономия на методите

- ❑ Според естеството на предсказваната променлива
 - *Класификатори* - Използва се за прогнозиране на категориална (дискретна) променлива (напр. № на клас, име, обект, събитие)
 - *Регресионен анализ* - Използва се за прогнозиране на непрекъснатата променлива (реално число, трендове на ст-ти)
- ❑ Таксономия на методите класификация
 - Дискриминативни класификатори
 - Генеративни класификатори
 - Хибридни методи
- ❑ Методи за обучение
 - Градиентни методи
 - Еволюционни методи
 - Deep Learning

Таксономия на класификаторите



Дискриминативни

Discriminative approaches

LDA

Polynomial
classifier

TDNN
and RNN

FFNN

SVM

Decision
trees

Недискриминативни и Генеративни

Non-discriminative approaches

k-NN

LVQ

SOM

PNN

GMM

HMM

Generative approaches

Combined methods

GMM/SVM

HMM/ANN

RBF

HMMs trained
discriminatively

PNN-RNN

Хибридни (комбинирани) методи

Таксономия на класификаторите



Discriminative approaches

LDA

Polynomial
classifier

TDNN
and RNN

FFNN

SVM

Decision
trees

Non-discriminative approaches

k-NN

LVQ

SOM

PNN

GMM

HMM

Generative approaches

Combined methods

GMM/SVM

HMM/ANN

RBF

HMMs trained
discriminatively

PNN-RNN

Епизодични

Последователни

Таксономия на класификаторите



Discriminative approaches

LDA

Polynomial
classifier

TDNN
and RNN

FFNN

SVM

Decision
trees

Non-discriminative approaches

k-NN

LVQ

SOM

PNN

GMM

HMM

Generative approaches

Combined methods

GMM/SVM

HMM/ANN

RBF

HMMs trained
discriminatively


PNN-RNN

Според принципа на учене

- Архитектури обучавани единствено чрез наблюдение
- Методи позволяващи интегриране на знание


Кой класификатор е най-добър?

Кой класификатор е най-добър?




<https://blog.easysol.net/building-ai-applications/>

Кой класификатор е най-добър?




<https://blog.easysol.net/building-ai-applications/>

Кой класификатор е най-добър?



<https://blog.easysol.net/building-ai-applications/>

Кой класификатор е най-добър?




<https://blog.easysol.net/building-ai-applications/>

Кой класификатор е най-добър?

Съгласно теоремата „Няма безплатен обяд“ не съществува метод, който да работи най-добре за всяка ситуация.

Предположенията и допусканията, валидни за конкретен супер-успешен модел, който решава конкретен проблем много успешно, може да не са валидни за другите модели.


Затова, типично за машинното обучение е да се експериментира с различни методи, за да се открие този, който се представя най-добре за конкретен проблем.




Дефиниции на задачите

Two-class decision problem		Multi-class decision problem	
One-class detection		Items identification Multi-label items identification	Item name(s)
One-class recognition Localization and tracking		Multi-class diarization	Item name(s) & time-stamps (location & trajectory)
One-group of classes recognition		Event type recognition Clustering of items/ events	Group name(s) (& time-stamps)


Детектор за един клас (One-class, single-class, or target class detection)




Идентификация на един измежду множество познати класове (Item/event identification)




Идентификация на всички налични “познати” класове (Multi-label item identification)




Разпознаване на една категория събития, т.е. една група събития (One-category recognition)




Разпознаване на едно събитие (One-class recognition)




Разпознаване на събития за множество класове, т.е. генериране на дневник на събитията (Multi-class diarization)




Локализация и проследяване на събития и обекти (Localization and tracking of individuals)



Разпознаване на типове събития генерирани от познати обекти (Event type recognition)




Търсене по пример/образец (Query-by-example search)




Общи понятия за процеса на обучение и работа на класификаторите

Процес на обучение на класификатор




Процеси при създаване на ML модел

Процес на обучение и работа на класификаторите




Обучение с надзор

Процес на обучение и работа на класификаторите



Събиране на данни от околната среда за обучение с надзор.

Процес на обучение и работа на класификаторите



Взаимодействие между околната среда при обучение с поощрение/подсилване.


Ресурси използвани при създаването на ML модели

Организация на данните необходими за създаване на класификатори. Предназначение, изисквания и спецификации на отделните типове набори от данни.


Пример:

Обработка на аудио сигнали (вкл. речеви сигнали)

Ресурси за ML = Аудио записи




Resources = Акустични записи




Обучаващи библиотеки

The Training Library (TL)




Акустична библиотека, представителна за околния свят

The acoustic background library (BL)




BL preparation workflow

Библиотека за валидиране The Validation Library (VL)



Библиотека за оценка на модела The Evaluation Library (EL)

При създаване VL и EL преминават през еднакви обработки, но EL трябва да съдържа по-голям брой записи



EL preparation workflow



Характеристични описатели (дескриптори) на обекти / събития / състояния



Описатели на обекти, събития...

- Директно използване на изображения/ видеа/ текстове/ звуци/ физиологични сигнали...

или индиректно, чрез извличане на информация от тях
(използване на знание за проблема)

- Извличане на характеристични описатели (дескриптори) представящи свойствата на сигнала/обекта/събитието:
 - ☐ във времевата област
 - ☐ в пространството (напр. геометрични)
 - ☐ в честотната област
 - ☐ във време-честотната област
 - ☐ в кепстралната област
 - ☐ в уейвлет област
 - ☐ в базис определен от структурата и съдържанието на изследваните сигнали / изображения / видеа
 - ☐ ...други...


Описатели във времевата област



Пример: Периферни физиологични сигнали (ЕКГ)

- ❑ BPM, mean heart rate; mean RR;
- ❑ mean, max and min NN interval; pNN50; SDNN; RMSSD; Standard deviation of the difference of successive NN intervals;
- ❑ SD1(Short term variability); SD2(Long term variability); SD1/SD2 ratio
- ❑ Number of Peaks, Mean, Max and Min Conductance, Conductance RMS, Standard Deviation of the conductance, Mean Resistance,
- ❑ First Quartile, Second Quartile, Third Quartile, Inter Quartile Range, Percentiles: 2.5, 10, 90, 97.5,


Описатели в честотната област




Пример: Периферни физиологични сигнали (ЕКГ)

- ❑ Power in (0-0.04)Hz, (0.04-0.15)Hz, (0.15-0.4)Hz bands;
- ❑ normalized powers in the three bands;
- ❑ the power in the three bands in percent;
- ❑ HRV (LF/HF ratio)


Описатели във време-честотната област



Кепстрални описатели на сигнали. Концептуален модел на речеобразуването.




Кепстрални описатели на сигнали. Инженерен модел на речеобразуването.




Кепстрални описатели на сигнали. Mel-Frequency Cepstral Coefficients (MFCC)



$$H(z) = 1 - \alpha \cdot z^{-1}$$

$$|FFT|^2$$

$$\log()$$



**Класификатор с архитектура „Детектор“ за
Откриване/разпознаване на един клас спрямо
целия останал свят**

Как?

**Чрез класификатор за два класа
(т.е. когато класовете не са равнопоставени от
гледната точка на потребителя).**

**One-class detection.
One-class recognition.**


Детектор за откриване/разпознаване на един клас





Детектор за откриване/разпознаване на един клас




Детектор за откриване/разпознаване на един клас



Детектор за откриване/разпознаване на един клас




Разпознаване на един клас чрез GMM-UBM класификатор (GMM-UBM-based species-specific recognizer)



**Класификатори използващи собствен модел
за всяка категория (клас)**

**Multi-class classifications with a single model
per category**


Класификация в множество класове с един модел за всеки клас (Multi-class classifications with a single model per category)



Класификатори използващи два или повече модели за представяне на всяка категория

Multi-class classifier with multiple models per category

Класификатор в много класове с повече от един модел за всеки клас (Multi-class classifier with multiple models per category)




Откриване на множество класове и множество събития, които се проявяват заедно в даден интервал от време

В реалния свят несвързани събития или обекти се появяват едновременно, като при това могат да се припокриват във времето и/или в пространството.

Multiple-species identification with a Multi-Instance Multi-Label (MIML) classifier


Multi-label item identification (Multi-class) Diarization

Откриване на множество класове и множество събития (Multiple-species identification with MIML classifier)



Откриване на множество класове с MIML класификатор

Multi-instance multi-label classification schemes



Идентификация на множество класове с MIML класификатор

Multiple-class identification with MIML classifier

Многостепенната задача за паралелното откриване на множество класове и множество техни прояви ($f_{MIML}: 2^X \rightarrow 2^Y$), може да бъде решена по два начина – или чрез редукция до откриване на множество прояви на един клас (**multi-instance learning**) или чрез откриване на множество класове/етикети/тагове (**multi-label learning**) при което MIML проблемите се трансформират до откриване на:

- Множество прояви на един клас (**multi-instance (MISL) task**), т.е. ($f_{MI}: 2^X \rightarrow Y$): Така опростена задачата, в последствие може да се сведе до обучение с надзор (**supervised single-instance single-label (SISL) problem**) ($f_{SISL}: X \rightarrow Y$),
- Множество различни етикети/тагове (**multi-label (MLSI) task**), т.е. ($f_{ML}: Z \rightarrow 2^Y$), където с помощта на преобразуваща функция ($\phi: 2^X \rightarrow Z$) множеството от прояви на един клас се свежда до една единствена (multi-instance bags to single-instance input). След това задачата може да се редуцира до обучение с надзор (**supervised single-instance single-label (SISL) problem**) ($f_{SISL}: Z \rightarrow Y$).

Въпроси?

