

Изкуствен интелект


Тема 6: Методи за машинно обучение. Статистически методи. Смеси от Гаусови функции (GMM).





Съдържание

- ❑ Класификация с невронни мрежи.
 - ✓ Без обратни връзки - MLPNN и PNN.
 - ✓ С обратни връзки - TDNN, RNN, DRNN, LRPNN, GLRPNN,...
- ❑ Статистически методи
 - Класификатор със смес от Гаусови функции (Gaussian Mixture Models, GMM)
 - Класификатор с опорни вектори (Support Vector Machine, SVM)
- ❑ Градиентни и Еволюционни (DE, PSO) методи за обучение на ML модели

Класификатори



Дискриминативни и генеративни методи

	Discriminative model	Generative model
Goal	Directly estimate $P(y x)$	Estimate $P(x y)$ to then deduce $P(y x)$
What's learned	Decision boundary	Probability distributions of the data
Illustration		
Examples	MLP NN, SVM, Decision trees, LDA...	PNN, GMM, Bayesian Networks ...



Класификатор със смес от Гаусови функции (Gaussian Mixture Models, GMM).

Класификатори

Discriminative approaches

LDA

Polynomial
classifier

TDNN
and RNN

FFNN

SVM

Decision
trees

Non-discriminative approaches

k-NN

LVQ

SOM

PNN

GMM

HMM

Generative approaches

Combined methods

GMM/SVM

HMM/ANN


RBF

HMMs trained
discriminatively

PNN-RNN

1-D Gaussian


$$\text{Normal}(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$



Параметрите са mean (μ) и variance (σ)

n-D Gaussian


$$\text{Normal}(\mathbf{x} \mid \mu, \Sigma) = \frac{1}{(2\pi)^2} \frac{1}{\det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma (\mathbf{x} - \mu) \right\}$$



При n-D дисперсията се заменя с ковариационната матрица

Ковариационна матрица на GMM


Spherical



(c)

$$\Sigma = \begin{pmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{pmatrix}$$


Diagonal



(b)

$$\Sigma = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}$$

Full covariance



(a)



$$\Sigma = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12}^2 \\ \sigma_{12}^2 & \sigma_{22}^2 \end{pmatrix}$$

За целият набор от данни изчисляваме log-likelihood*:

$$\ln p(X) = \ln \prod_{n=1}^N \text{Normal}(\mathbf{x}_n \mid \mu, \Sigma)$$

* log-likelihood = логаритъм от правдоподобността


Смес от Гаусови функции



В реалния живот данните рядко могат да се опишат с една Гаусова крива, но може да се ползва комбинация от няколко...

Смес от Гаусови функции

$$p(\mathbf{x}) = \sum_{k=1}^M \pi_k \text{Normal}(\mathbf{x} \mid \mu_k, \Sigma_k)$$






Смес от Гаусови функции

$$p(\mathbf{x}) = \sum_{k=1}^M \pi_k \text{Normal}(\mathbf{x} \mid \mu_k, \Sigma_k)$$

- В допълнение към средната стойност и ковариационните параметри (M пъти), имаме и тегловните коефициенти π_k .

$$\sum_{k=1}^M \pi_k = 1 \quad 0 \leq \pi_k \leq 1$$

Смес от Гаусови функции



$$\gamma_k(\mathbf{x}) = p(k | \mathbf{x})$$

$$p(\mathbf{x}) = \sum_{k=1}^M p(k) p(\mathbf{x} | k)$$

$$= \frac{p(\mathbf{x}) p(\mathbf{x} | k)}{\sum_l p(l) p(\mathbf{x} | l)}$$

$$= \frac{\pi_k \text{Normal}(\mathbf{x} | \mu_k, \Sigma_k)}{\sum_l \pi_l \text{Normal}(\mathbf{x} | \mu_l, \Sigma_l)}$$

Expectation Maximization (EM)

■ Цел:

Да се максимизира log-likelihood за целия набор от данни

$$\ln p(\mathbf{X} | \Pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^M \pi_k \text{Normal}(\mathbf{x}_n | \mu_k, \Sigma_k) \right\}$$

Като изчисляваме апроксимацията на класовете, можем да максимизираме индивидуално:

- ❑ средните стойности,
- ❑ ковариационните матрици,
- ❑ тегловните коефициенти за отделните компоненти

Expectation Maximization (EM)

Оценка на средна стойност:

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \gamma_k(\mathbf{x}_n) \mathbf{x}_n \quad N_k = \sum_{n=1}^N \gamma_k(\mathbf{x}_n)$$

Оценка на ковариационните матрици

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma_k(\mathbf{x}_n) (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

Оценка на тегловните коефициенти

$$\pi_k = \frac{N_k}{N}$$

$$\gamma_k(\mathbf{x}) = p(k | \mathbf{x})$$


$$= \frac{p(\mathbf{x}) p(\mathbf{x} | k)}{\sum_l p(l) p(\mathbf{x} | l)}$$

$$= \frac{\pi_k \text{Normal}(\mathbf{x} | \mu_k, \Sigma_k)}{\sum_l \pi_l \text{Normal}(\mathbf{x} | \mu_l, \Sigma_l)}$$

Expectation Maximization (EM)

- Инициализация на параметрите
- Повтаряй до достигане на сходимост
 - **Е стъпка:** изчисляване на класовата принадлежност
 - **М стъпка:** преизчисляване на параметрите
 - Изчисляване на log likelihood за новите параметри


Expectation Maximization (EM)





Съдържание

- ☐ Обща класификация на методите
- ☐ Класификация с невронни мрежи. Архитектури.
MLPNN и PNN.
- ☐ Рекурентни невронни мрежи (RNN, LRPNN,
GLRPNN)
- ☐ Статистически методи (GMM, HMM)
- ☐ Класификация с опорни вектори (SVM)
- ☐ Еволюционни и генетични методи за оптимизация
(DE, PSO)

Скрити модели на Марков



Дискриминативни и генеративни методи

	Discriminative model	Generative model
Goal	Directly estimate $P(y x)$	Estimate $P(x y)$ to then deduce $P(y x)$
What's learned	Decision boundary	Probability distributions of the data
Illustration		
Examples	MLP NN, SVM, Decision trees, LDA...	PNN, GMM, Bayesian Networks ...