


Изкуствен интелект

Тема 8: Методи за машинно обучение. Регресия. Линейна регресия. Анализ на грешката.




Регресия, регресионен анализ

- ❑ Регресията цели да обясни (моделира) изменението на зависимата променлива използвайки знание за измененията на една или повече независими променливи.
- ❑ Регресията е следствие от каузалността.
- ❑ Ако независимите променливи са свързани с измененията на зависимата променлива, моделът може да се използва за предсказване...




Регресия, регресионен анализ




Проста линейна регресия

Резултатът от регресията е функцията, която предсказва зависимата променлива въз основа на стойностите на независимата променлива.

При простата линейна регресия апроксимираме с помощта на права линия.




Проста линейна регресия



Функцията трябва да предскаже ст-та на зависимата променлива y по зададена ст-ст на x

Наблюдаваната ст-ст е означена с y , а предсказаната с $y^{\wedge}$.

Проста линейна регресия




За всяко наблюдение, отклонението може да бъде означено като:

$$y = \hat{y} + \varepsilon$$

истинска = обяснена + грешка


Регресия



По метода на най-малките квадрати може да се избере линия която да доведе до най-малката стойност на сумата от квадрата на грешките на предсказване.

Тази стойност се нарича сума от квадратите на грешката (Sum of Squares of Error, SSE).

Регресия



Регресия със сума от квадратите -- сумата от квадратите на разликите м/у предсказаната стойност на всяко наблюдение и средната стойност на популацията.

Регресия

Обща сума на квадратите (Total Sum of Squares, SST) е

$$SST = SSE + SSR$$

Total sum
of Squares

Sum of
Squares Error

Sum of Squares
Regression

$$SST = \sum (y - \bar{y})^2$$

мярка за общата
изменчивост на y

$$SSE = \sum (y - \hat{y})^2$$

мярка за необяснената
от $\hat{y}$ промяна

$$SSR = \sum (\hat{y} - \bar{y})^2$$

мярка за обяснимата
промяна


where:

$\bar{y}$ = средна ст-ст за зависимата променлива

y = наблюдавана стойност

$\hat{y}$ = очаквана стойност на y при зададено x

Регресия



Регресия

Пропорцията на общата изменчивост (SST) отнесена към мярка за обяснимата промяна чрез регресията (SSR) се нарича коефициент на определеност (Coefficient of Determination), често се означава с R^2 .

$$R^2 = \frac{SSR}{SST} = \frac{SSR}{SSR + SSE}$$

$$0 \leq R^2 \leq 1$$

Стойността на R^2 е м/у 0 и 1, и колкото е по-висока, толкова по-точен е модела на регресията.

$$R^2 = \frac{SSR}{SST} = \frac{\text{sum of squares explained by regression}}{\text{total sum of squares}}$$

Регресия

Оценката на достоверния интервал за отделна ст-ст на y при дадена определена ст-ст на x_p

$$\hat{y} \pm t_{\alpha/2} s_{\varepsilon} \sqrt{1 + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum (x - \bar{x})^2}}$$

Този член добавен към ширината на интервала отговаря на добавената несигурност за всеки отделен случай

Стандартна грешка при регресията

- Стандартна грешка при регресията е мярката за нейната вариативност и може да се използва в смисъла на стандартното отклонение, за предсказване на интервалите на достоверност.
- $y \pm 2$ стандартни грешки осигурява прецизност от приблизително 95%, а 3 стандартни грешки осигуряват доверителен интервал от 99%.
- Стандартната грешка се определя като корен квадратен от средната грешка на предсказване.

$$s_{\varepsilon} = \sqrt{\frac{SSE}{n - k - 1}}$$

n е броя наблюдения в извадката

k е общия брой на променливите в модела

Стандартна грешка при регресията

Стандартната грешка на коефициента на наклон на регресията (b_1) е

$$s_{b_1} = \frac{s_\varepsilon}{\sqrt{\sum (x - \bar{x})^2}} = \frac{s_\varepsilon}{\sqrt{\sum x^2 - \frac{(\sum x)^2}{n}}}$$


където:

s_{b_1} = оценка на стандартната грешка по метода на най-малките квадрати

$s_\varepsilon = \sqrt{\frac{SSE}{n-2}}$ = оценка на стандартната грешка за извадката



Интервална оценка за различни ст-ти на x

Интервал на прогнозиране за конкретна стойност на y , при зададена ст-ст x_p




Стандартна грешка при регресията

Отклонение от линейния
регресивен модел



Изменчивост в наклона на
модела спрямо ст-стите



Анализ на грешката



■ Цел

- ☐ За да се провери допускането за линейност
- ☐ Да провери дали стандартното отклонение за всяка стойност на x дали е еднаква
- ☐ Да се оцени допускането за нормалност на разпределението



■ Графичен анализ на грешката

- ☐ Можем да изобразим грешката спрямо x
- ☐ Можем да построим хистограма на грешката за да проверим за нормалност


Анализ на грешката за линейност





Анализ на грешката за константно отклонение




Анализ на грешката за независимост



Грешката е ф-я на X




Независима от X





Примери


$$0 < R^2 < 1$$






$$R^2 = 1$$



$$R^2 = 1$$





Примери



Примери

$$R^2 = 0$$



Проста линейна регресия

Резултатът от проста линейна регресия е изчислена стойност на коефициента β и константата A :

$$y = A + \beta * x + \varepsilon$$

където ε е остатъчната грешка.


β е изменението на зависимата променлива при единично изменение на независимата променлива:

$$\beta = \frac{\Delta y}{\Delta x}$$

$$\hat{\beta} = \frac{Cov(x, y)}{Var(x)}$$

$$\text{Calculate : } \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

Нелинейна регресия



Нелинейна функция също може да бъде апроксимираща функция на регресията – например квадратична функция, логаритмична функция, експоненциална функция, или всяка друга непрекъсната функция.

Множествена линейна регресия

Множествена линейна регресия - когато има повече от една независима променлива, която може да се използва за да се обясни изменението на зависимата променлива, но с ограничението независимите променливи да не са линейно свързани.

Множествена линейна регресия се дефинира като

$$y = A + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

където k е броя на променливите или параметрите на модела.

Мультиколинеарност

Мультиколинеарност е условието при което най-малко 2 независими променливи са линейно корелирани.

*Example table of
Correlations*

	Y	X1	X2
Y	1.000		
X1	0.802	1.000	
X2	0.848	0.578	1.000

Корелационната таблица подсказва кои независими променливи са свързани.

В общия случай, независимата променлива която има ст-ст на корелацията по-голяма от 0.3 със зависимата променлива и по-малко от 0.7 с всяка друга независима променлива която може да се използва като предсказател.

Въпроси?

