




Съвременни методи за машинно обучение


**Тема 11: Конволюционни невронни
мрежи (Convolutional neural networks,
CNN). Архитектури, особености,
ограничения, области на приложение.
Примери.**

Съдържание

- Въведение
- Понятие за CNN
- LeNet5
- AlexNet
- ...



Семейството на CNN



Въведение



Yann LeCun и **Yoshua Bengio** публикуват концепцията на конволюционните невронни мрежи (convolutional neural networks, CNN) през 1995г.

Въведение


- CNN са вдъхновени от откритията на **невробиологията**, показващи че в областта от мозъка (visual cortex), която осъществява функциите на зрението, има нервни клетки които са локално чувствителни и са чувствителни към ориентацията.
- **Yann LeCun** и **Yoshua Bengio** създават структура на мрежа която по подразбиране извлича съответните характеристики на обектите.
- Convolutional Neural Networks могат да се разглеждат като един вид **multi-layer neural networks**.

Въведение


- CNN е еднопосочна (**feed-forward**) мрежа която може да извлече топологични свойства от изображение.
- Като много други невронни мрежи те са обучени с версия на алгоритъма обратно разпространение на грешката (**back-propagation**).
- CNN са предназначени да разпознават обекти в изображения директно от пикселите, с минимална предварителна обработка.
- CNN могат да бъдат научени да разпознават изображения, дори когато се характеризират с екстремна изменчивост (разпознаване на ръкописни знаци).

Понятие за CNN

■ Традиционен ML алгоритъм




■ CNN





Понятие за CNN


Традиционна напълно свързана мрежа с един скрит слой



Input Image
16 * 16



Слоеве с пълна свързаност



An example of fully connected layer.


Защо да използваме по-дълбока мрежа?

- ❑ По-дълбоките мрежи могат да използват доста по-малко неврони за слой и много по-малко параметри
- ❑ Често имат по-добра точност на тестовия набор от данни въпреки че са по икономични.
- ❑ **По трудни са за оптимизиране!**
- ❑ Когато избираме дълбока архитектура обикновено сме мотивирани от допускането (вярваме), че искаме да „научим“ композитна функция която се състои от няколко по-елементарни функции.
- ❑ Или обучението има за цел да открие набор от основни фактори на вариация, които могат на свой ред да бъдат описани от гледна точка на други, по-прости основни фактори на изменчивост.


„Проклятието на големият брой измерения“

- ❑ Основния замисъл на deep learning се състои в допускането, че данните са генерирани от процес включващ голям набор от фактори или характеристики, по всяка вероятност от множество различни нива на йерархия.
- ❑ Това допускане позволява експоненциална печалба в съотношението между броя на примерите и броя на регионите, които могат да бъдат разграничени.
- ❑ Експоненциалното предимство в резултат на използването на дълбоко разпределено представяне е в противовес на експоненциалните проблеми обусловени от „проклятието на големия брой измерения“.

Понятие за CNN




В противовес на абстракцията свързана с 1D характеристикните вектори в невронните мрежи, CNN възвръща двумерната (2D) решетка при обработката на изображения и внася дълбочина в слоевете от неврони.



Понятие за CNN

Характеристични карти (Feature maps)



Извличане на описатели

Feature extraction layer

Convolution layer

Пуллинг/децимиращ/редуциращ слой



Инвариантност към отместване и деформации

Shift and distortion invariance or




Subsampling layer

Понятие за CNN


- Конволюционният слой открива едни и същи характеристики на различни позиции във входното изображение.



Извличане на характеристики




Извличане на характеристики



<http://blog.csdn.net/somTian>


Извличане на характеристики

- **Споделени тегловни коефициенти**: всички неврони отнасящи се за дадена характеристика споделят еднакви тегловни коефициенти. Това не се отнася за отместванията (biases).
- Така, всички неврони откриват една и съща характеристика **на различни позиции** във входното изображение.
- **Намалява се** броят на свободните параметри (обучаемите тегла).




Извличане на характеристики

- Когато даден неврон в характеристикната карта се активира (висока ст-ст в изхода), това означава, че е „разпознал“ елемента зададен с маската/филтъра.




Редуциращ/Децимиращ слой


- Pooling/Редуциращият/децимиращият слой се използва **за намаляване** на пространствената разделителна способност на характеристичните карти.
- Намаляването на пространствената резолюция на характеристичните карти допринася в известна степен за **инвариантност** към отмествания и деградация на обектите.




Редуциращ/Децимиращ слой



- Последователното прилагане на редуциращи слоеве намалява на разделителната способност на характеристикните карти.




Редуциращ/Децимиращ слой




Редуциращ/Децимиращ слой

В редуциращия слой също се прилага споделяне на тегловните коефициенти (**weight sharing**).




Pooling / Редуциращ / Децимиращ слой



Pooling layer downsamples the volume spatially, independently in each depth slice of the input volume. **Left:** In this example, the input volume of size $[224 \times 224 \times 64]$ is pooled with filter size 2, stride 2 into output volume of size $[112 \times 112 \times 64]$. Notice that the volume depth is preserved. **Right:** The most common downsampling operation is max, giving rise to **max pooling**, here shown with a stride of 2. That is, each max is taken over 4 numbers (little 2x2 square).



Pooling




Редуциращ/Децимиращ слой

- Споделянето на теглата в редуциращия слой **намалява ефекта** от наличието на шум и отместване или деградация на обектите

Feature map



До тук знаем...



Недостатъци на CNN

- ☯ От гледна точка на количеството памет и възможности **CNN** не е много по-голяма от обикновена двуслойна мрежа за същата цел.
- ☯ По време на експлоатацията **конволюционните пресмятания** са трудоемки за изчисляване и отнемат около **67%** от общото време за пресмятане на изходния резултат.
- ☯ CNN е около **3X** по-бавна от еквивалентна напълно свързана невронна мрежа (със същия размер).

Недостатъци на CNN

❑ Операцията конволюция

- ❑ 4 вложени **цикъла** (2 цикъла за входното изображение и други 2 цикъла за кърнела)

❑ Малък размер на кърнела


- ❑ Водят до много **неефективни вътрешни цикли** тъй като те често **JMP**.

❑ Не използват ефективно Кеша (Cash memory)

- ❑ **Back-propagation** изисква едновременно достъп до входното изображение и кърнела достъп по редове и по колони.
- ❑ **2-D изображенията** се представят серийно по редове.
- ❑ **Достъпът до данните по колони** може да предизвика много неудобства при използването на кеша (липсващи ст-ти).

Част II

Конволюционни невронни мрежи (CNN). Архитектури, особености, ограничения, области на приложение. Примери.





CNN – какво знаем до момента?

Архитектурата на CNN заимства идеи от областта на неврологията (Neuroscience)

- Основно от областта от мозъчната кора, която отговаря за първичното зрение (the primary visual cortex, V1) за който имаме повече изследвания
- Областта от мозъка известна като LGN (lateral geniculate nucleus), разположена в задната част на главата пренася сигналите от очите до областта V1,
- Конволюционният слой пресъздава 3 аспекта на V1
 - V1 има двуизмерна структура
 - V1 съдържа голям брой прости клетки, линейни елементи
 - V1 съдържа голям брой сложни клетки, съответстващи на характеристики които имат инвариантност към премествания, подобно на pooling операциите






CNN – какво знаем до момента?

- Когато погледнем към даден обект, информацията формирана в ретината се пренася чрез LGN към V1, след което към V2, после към V4, след което към инферо-темпоралната област от мозъчната кора, т.е. IT (inferotemporal cortex), и съответстваща на последния слой от архитектурата на CNN
- Насочването на вниманието (attention mechanism) към определена област от пространството засега е слабо-проучено. Има го при всички бозайници.
 - Човешкото око е с предимно много ниска пространствена разделителна способност, с изключение на малка част – петното на фовеята (fovea).
 - Чрез очите се извършват няколко сканирания за да може мозъка да забележи характерните компоненти от сцената.
 - Човешкото зрение възприема 3D реалността.

CNN



Всяка елементарна клетка от V1 областта реагира на определена пространствено-обусловена честота на яркост в определена посока на определено място – при което се реализират функции, подобни на операторите на Габор



CNN





В резултат на което CNN „научава“ характеристиките получени от прилагането на функциите на Габор



CNN


Рецептивно поле



Вляво: Примерен “обем” на входа в червено (напр. изображение 32x32x3 CIFAR-10) и примерен «обем» на невроните в първия конволюционен слой. Всеки неврон в конволюционния слой е свързан пространствено само с локална област от входното изображение, но с пълната дълбочина (т.е. всички цветни канали). Имайте предвид, че по дълбочината има множество неврони (5 в този пример), всички гледащи един и същ регион във входа.

Вдясно: Невроните са като при всяка невронна мрежа: Те изчисляват «точков продукт» на техните тегла с входа, последван от нелинейност, но тяхната свързаност сега е ограничена пространствено – локална част от изображението, локална свързаност.

Поради това, въпреки че директната свързаност в CNN е слаба, невроните в дълбоките слоеве могат да са индиректно свързани с повечето (или всички) пиксели от входното изображение.



CNN

Операциите конволюция и pooling действат като безкрайно силно допускане (prior probability)

- силното допускане води до много ниска ст-ст на ентропията, например Гаусова функция с малка дисперсия
- безкрайно силно допускане означава, че някои параметри са „забранени“ и вероятността им е равна на нула
- Конволюционният „prior“ показва идентичните и нулеви тегла
- Операцията pooling води до инвариантност при малки премествания (translations)

CNN архитектури

Терминология:

- Слоеве: complex/complete или simple ?
 - simple - конволюция
 - complex (complete) конволюционен слой включва различни етапи на обработка, в т.ч. самата конволюция, нормализацията (batch normalization), прилагането на нелинейна функция (nonlinearity), и редукцията на размерността чрез pooling
 - Всеки етап на обработката е един слой, даже и да няма параметри

CNN архитектури

- Традиционните CNNs включват няколко конволюционни слоя, които да извлекат характеристичните описатели след което следва изходният класифициращ слой със softmax неврони
- Изходът от CNN е тензор -- многомерен, структуриран обект, а не само предсказаният конкретен клас. Това е основна разлика спрямо традиционните схеми за класификация и спрямо реалната стойност определена при регресията.
- CNN изчислява $S_{i,j,k}$ – вероятността пикселът с координати j,k да принадлежи на клас i


Обобщение:

- Конвенционалната линейна архитектура, линеен набор от слоеве, следва се принципа за еднопосочност на информацията (feedforward)
- В общия случай това е DAG (directed acyclic graph)

LeNet 5


LeNet5

- LeNet5 е предложена от LeCun
- MNIST разпознаване на 10 ръкописни цифри
- Входно изображение от 32×32 пиксела.



LeNet5: Архитектура

- **C1, C3, C5** : Convolutional layer.
- **5 × 5** Convolution matrix.
- **S2, S4** : Subsampling layer.
- Subsampling by factor **2**.
- **F6** : Fully connected layer.




LeNet5





Всички слоеве до F6 използват **sigmoidal** активираща функция от типа:


$$y_j = \varphi(v_j) = A \tanh(Sv_j)$$



LeNet5




$$Y_j = \sum_{i=1}^{84} (F_i - W_{ij})^2, j = 0, \dots, 9$$




Приблизително

- 187,000 връзки.
- 14,000 тегл. коеф.
- за обучение.




LeNet5



LeNet5




answer: 4


444
555

answer: 2


222
222



44
f f f f f f f f



answer: 6

66
668

Литература

- Yunzhe Xue, Convolutional neural network for Image recognition, <http://cs231n.github.io/convolutional-networks/>
- Abin – Roozgard, Convolutional neural networks
- Y. LeCun and Y. Bengio. "Convolutional networks for images, speech, and time-series." In M. A. Arbib, editor, The Handbook of Brain Theory and Neural Networks. MIT Press, 1995.
- Fabien Lauer, Ching Y. Suen, Gérard Bloch, "A trainable feature extractor for handwritten digit recognition", Elsevier, October 2006.
- Patrice Y. Simard, Dave Steinkraus, John Platt, "Best Practices for Convolutional Neural Networks Applied to Visual Document Analysis," Proc. of the ICDAR-2003, Los Alamitos, pp. 958-962.